




Guatemala 4 de junio de 2026

**Universidad Galileo
Facultad De Ingeniería De Sistemas, Informática Y
Ciencias De La Computación
Postgrado Inteligencia Artificial
Fundamentos Modernos de la IA
Profesor: Kevin José Hernández Marroquín**

**Alumno: Edgar Estuardo Dueñas de León
Carné: 0910296**

Laboratorio 01 - Exploración de Datos

Objetivos: Analizar los tres conjuntos de datos almacenados en las bases de datos MySQL que estoy corriendo, utilizando Docker, las bases de datos se llaman: `pia\_data\_01`, `pia\_data\_02` y `pia\_data\_03` (todas con la tabla `salaries`), alojadas en el entorno de docker compose, para detectar problemas comunes de calidad de datos:

1. Datos faltantes (*Missing Data*)
2. Problemas de escala (*Scaling Issues*)
3. Clases desbalanceadas (*Imbalanced Classes*)
4. Valores anómalos (*Outliers*)
5. Problemas de formato
6. Problemas de estandarización

Adicionalmente he analizado la distribución de cada variable para identificar patrones, sesgos y particularidades (formas de la distribución, mezcla de distribuciones, etc.). Este análisis lo realice en un notebook llamado Laboratorio 01- Exploración de Datos.ipynb (repositorio: <https://github.com/ieddu/Laboratorio-01-Exploracion-de-Datos>) y el informe detallado con los hallazgos obtenidos por cada una de las características del dataset se presentan a continuación.

Conjunto de datos: pia_data_01 (tabla salaries)

Dimensiones: 710 registros x 15 columnas.

Informe de hallazgos por característica generado a partir del análisis exploratorio de datos (EDA).

Análisis por característica

Feature: gender

Datos Faltantes: Sí, 35 registros (4.93%)

Anomalías: No

Clases no Balanceadas: No, las 2 clases están balanceadas (ratio min/max=0.824)

Problemas de Formato: Sí, es una variable categórica (texto): requiere codificación para modelado

Problemas de Estandarización: No

Distribución de Datos: Categórica (distribución de frecuencias por clase)

Sesgo: No aplica (variable categórica)

Múltiples Distribuciones: No

Feature: age

Datos Faltantes: Sí, 14 registros (1.97%)

Anomalías: No

Clases no Balanceadas: No aplica, es una variable numérica continua

Problemas de Formato: Sí, son edades enteras almacenadas como decimal (p. ej. 30.0)

Problemas de Estandarización: Sí, conviene escalar (rangos distintos) para algoritmos sensibles a la escala

Distribución de Datos: aproximadamente uniforme

Sesgo: Sin sesgo apreciable (simétrica)

Múltiples Distribuciones: No

Feature: country

Datos Faltantes: No

Anomalías: Sí, variable constante (sin variabilidad)

Clases no Balanceadas: No aplica, variable constante (1 clase)

Problemas de Formato: Sí, es una variable categórica (texto): requiere codificación para modelado

Problemas de Estandarización: No

Distribución de Datos: Categórica (distribución de frecuencias por clase)

Sesgo: No aplica (variable categórica)

Múltiples Distribuciones: No

Feature: married

Datos Faltantes: No

Anomalías: No

Clases no Balanceadas: No, las 2 clases están balanceadas (ratio min/max=0.919)

Problemas de Formato: Sí, es booleana representada como entero 0/1 (requiere mapeo a True/False)

Problemas de Estandarización: No

Distribución de Datos: Categórica (distribución de frecuencias por clase)

Sesgo: No aplica (variable categórica)

Múltiples Distribuciones: No

Feature: family_members

Datos Faltantes: No

Anomalías: No

Clases no Balanceadas: No aplica, es una variable numérica discreta

Problemas de Formato: No, es una variable numérica

Problemas de Estandarización: No

Distribución de Datos: aproximadamente uniforme

Sesgo: Sin sesgo apreciable (simétrica)

Múltiples Distribuciones: No

Feature: industry

Datos Faltantes: No

Anomalías: No

Clases no Balanceadas: No, las 8 clases están balanceadas (ratio min/max=0.736)

Problemas de Formato: Sí, es una variable categórica (texto): requiere codificación para modelado

Problemas de Estandarización: No

Distribución de Datos: Categórica (distribución de frecuencias por clase)

Sesgo: No aplica (variable categórica)

Múltiples Distribuciones: No

Feature: income_flux

Datos Faltantes: Sí, 26 registros (3.66%)

Anomalías: Sí, 1 outliers por IQR (fuera de [-15760.25, 28933.75])

Clases no Balanceadas: No aplica, es una variable numérica continua

Problemas de Formato: No, es una variable numérica

Problemas de Estandarización: Sí, magnitud elevada respecto a otras variables; requiere escalamiento

Distribución de Datos: sesgada (cola hacia valores altos); con un pico pronunciado en 0

Sesgo: A la derecha (positivo)

Múltiples Distribuciones: Sí, mezcla del grupo con ingreso 0 (desempleados) y el resto

Feature: outgoing_flux

Datos Faltantes: Sí, 35 registros (4.93%)

Anomalías: Sí, 12 outliers por IQR (fuera de [-5774.75, 12535.25])

Clases no Balanceadas: No aplica, es una variable numérica continua

Problemas de Formato: No, es una variable numérica

Problemas de Estandarización: Sí, magnitud elevada respecto a otras variables; requiere escalamiento

Distribución de Datos: sesgada (cola hacia valores altos)

Sesgo: A la derecha (positivo)

Múltiples Distribuciones: No

Feature: education_level

Datos Faltantes: Sí, 21 registros (2.96%)

Anomalías: No

Clases no Balanceadas: Sí, existen 5 clases y están desbalanceadas (ratio min/max=0.111); domina 'Bachelor'

Problemas de Formato: Sí, es una variable categórica (texto): requiere codificación para modelado

Problemas de Estandarización: No

Distribución de Datos: Categórica (distribución de frecuencias por clase)

Sesgo: No aplica (variable categórica)

Múltiples Distribuciones: No

Feature: years_of_experience

Datos Faltantes: No

Anomalías: No

Clases no Balanceadas: No aplica, es una variable numérica discreta

Problemas de Formato: No, es una variable numérica

Problemas de Estandarización: Sí, conviene escalar (rangos distintos) para algoritmos sensibles a la escala

Distribución de Datos: aproximadamente uniforme

Sesgo: Sin sesgo apreciable (simétrica)

Múltiples Distribuciones: No

Feature: employment_type

Datos Faltantes: Sí, 21 registros (2.96%)

Anomalías: No

Clases no Balanceadas: No, las 4 clases están balanceadas (ratio min/max=0.758)

Problemas de Formato: Sí, es una variable categórica (texto): requiere codificación para modelado

Problemas de Estandarización: No

Distribución de Datos: Categórica (distribución de frecuencias por clase)

Sesgo: No aplica (variable categórica)

Múltiples Distribuciones: No

Feature: remote_work_percentage

Datos Faltantes: No

Anomalías: No

Clases no Balanceadas: No aplica, es una variable numérica continua

Problemas de Formato: No en la BD (INT), pero el origen traía artefactos de punto flotante (p. ej. 56.999...) que requieren redondeo

Problemas de Estandarización: Sí, conviene escalar (rangos distintos) para algoritmos sensibles a la escala

Distribución de Datos: aproximadamente simétrica (campana); con un pico pronunciado en 0

Sesgo: Sin sesgo apreciable (simétrica)

Múltiples Distribuciones: No

Feature: currency

Datos Faltantes: Sí, 35 registros (4.93%)

Anomalías: Sí, variable constante (sin variabilidad)

Clases no Balanceadas: No aplica, variable constante (1 clase)

Problemas de Formato: Sí, es una variable categórica (texto): requiere codificación para modelado

Problemas de Estandarización: No

Distribución de Datos: Categórica (distribución de frecuencias por clase)

Sesgo: No aplica (variable categórica)

Múltiples Distribuciones: No

Feature: salary_satisfaction

Datos Faltantes: No

Anomalías: No

Clases no Balanceadas: No, las 5 clases están balanceadas (ratio min/max=0.839)

Problemas de Formato: No, es una variable numérica

Problemas de Estandarización: No

Distribución de Datos: aproximadamente uniforme

Sesgo: Sin sesgo apreciable (simétrica)

Múltiples Distribuciones: No

Observaciones del dataset

- Presentan datos faltantes las variables: gender, age, income_flux, outgoing_flux, education_level, employment_type, currency.
- Los faltantes de currency, income_flux y outgoing_flux están correlacionados (faltante estructurado): cuando falta la moneda, también faltan ingresos y egresos.
- income_flux y outgoing_flux tienen magnitudes muy superiores al resto de variables, por lo que requieren normalización/estandarización.
- education_level está desbalanceada: domina 'Bachelor'.
- Variables constantes (sin variabilidad): country, currency.
- married es booleana almacenada como 0/1 y age son enteros almacenados como decimal: ambos presentan problemas de formato menores.
- income_flux y outgoing_flux presentan distribuciones sesgadas a la derecha; un pico en 0 corresponde a personas desempleadas.

Conjunto de datos: pia_data_02 (tabla salaries)

Dimensiones: 1050 registros x 15 columnas.

Informe de hallazgos por característica generado a partir del análisis exploratorio de datos (EDA).

Análisis por característica

Feature: gender

Datos Faltantes: Sí, 52 registros (4.95%)

Anomalías: No

Clases no Balanceadas: No, las 2 clases están balanceadas (ratio min/max=0.949)

Problemas de Formato: Sí, es una variable categórica (texto): requiere codificación para modelado

Problemas de Estandarización: No

Distribución de Datos: Categórica (distribución de frecuencias por clase)

Sesgo: No aplica (variable categórica)

Múltiples Distribuciones: No

Feature: age

Datos Faltantes: Sí, 21 registros (2.0%)

Anomalías: No

Clases no Balanceadas: No aplica, es una variable numérica continua

Problemas de Formato: Sí, son edades enteras almacenadas como decimal (p. ej. 30.0)

Problemas de Estandarización: Sí, conviene escalar (rangos distintos) para algoritmos sensibles a la escala

Distribución de Datos: aproximadamente uniforme

Sesgo: Sin sesgo apreciable (simétrica)

Múltiples Distribuciones: No

Feature: country

Datos Faltantes: No

Anomalías: Sí, variable constante (sin variabilidad)

Clases no Balanceadas: No aplica, variable constante (1 clase)

Problemas de Formato: Sí, es una variable categórica (texto): requiere codificación para modelado

Problemas de Estandarización: No

Distribución de Datos: Categórica (distribución de frecuencias por clase)

Sesgo: No aplica (variable categórica)

Múltiples Distribuciones: No

Feature: married

Datos Faltantes: No

Anomalías: No

Clases no Balanceadas: No, las 2 clases están balanceadas (ratio min/max=0.996)

Problemas de Formato: Sí, es booleana representada como entero 0/1 (requiere mapeo a True/False)

Problemas de Estandarización: No

Distribución de Datos: Categórica (distribución de frecuencias por clase)

Sesgo: No aplica (variable categórica)

Múltiples Distribuciones: No

Feature: family_members

Datos Faltantes: No

Anomalías: No

Clases no Balanceadas: No aplica, es una variable numérica discreta

Problemas de Formato: No, es una variable numérica

Problemas de Estandarización: No

Distribución de Datos: aproximadamente uniforme

Sesgo: Sin sesgo apreciable (simétrica)

Múltiples Distribuciones: No

Feature: industry

Datos Faltantes: No

Anomalías: No

Clases no Balanceadas: No, las 10 clases están balanceadas (ratio min/max=0.683)

Problemas de Formato: Sí, es una variable categórica (texto): requiere codificación para modelado

Problemas de Estandarización: No

Distribución de Datos: Categórica (distribución de frecuencias por clase)

Sesgo: No aplica (variable categórica)

Múltiples Distribuciones: No

Feature: income_flux

Datos Faltantes: Sí, 40 registros (3.81%)

Anomalías: Sí, 1 outliers por IQR (fuera de [-19279.5, 107902.5])

Clases no Balanceadas: No aplica, es una variable numérica continua

Problemas de Formato: No, es una variable numérica

Problemas de Estandarización: Sí, magnitud elevada respecto a otras variables; requiere escalamiento

Distribución de Datos: aproximadamente simétrica (campana); con un pico pronunciado en 0

Sesgo: Sin sesgo apreciable (simétrica)

Múltiples Distribuciones: Sí, mezcla del grupo con ingreso 0 (desempleados) y el resto

Feature: outgoing_flux

Datos Faltantes: Sí, 52 registros (4.95%)

Anomalías: Sí, 14 outliers por IQR (fuera de [-10634.62, 53858.38])

Clases no Balanceadas: No aplica, es una variable numérica continua

Problemas de Formato: No, es una variable numérica

Problemas de Estandarización: Sí, magnitud elevada respecto a otras variables; requiere escalamiento

Distribución de Datos: sesgada (cola hacia valores altos)

Sesgo: A la derecha (positivo)

Múltiples Distribuciones: No

Feature: education_level

Datos Faltantes: Sí, 31 registros (2.95%)

Anomalías: No

Clases no Balanceadas: Sí, existen 5 clases y están desbalanceadas (ratio min/max=0.125); domina 'Bachelor'

Problemas de Formato: Sí, es una variable categórica (texto): requiere codificación para modelado

Problemas de Estandarización: No

Distribución de Datos: Categórica (distribución de frecuencias por clase)

Sesgo: No aplica (variable categórica)

Múltiples Distribuciones: No

Feature: years_of_experience

Datos Faltantes: No

Anomalías: No

Clases no Balanceadas: No aplica, es una variable numérica discreta

Problemas de Formato: No, es una variable numérica

Problemas de Estandarización: Sí, conviene escalar (rangos distintos) para algoritmos sensibles a la escala

Distribución de Datos: aproximadamente uniforme

Sesgo: Sin sesgo apreciable (simétrica)

Múltiples Distribuciones: No

Feature: employment_type

Datos Faltantes: Sí, 31 registros (2.95%)

Anomalías: No

Clases no Balanceadas: No, las 4 clases están balanceadas (ratio min/max=0.914)

Problemas de Formato: Sí, es una variable categórica (texto): requiere codificación para modelado

Problemas de Estandarización: No

Distribución de Datos: Categórica (distribución de frecuencias por clase)

Sesgo: No aplica (variable categórica)

Múltiples Distribuciones: No

Feature: remote_work_percentage

Datos Faltantes: No

Anomalías: No

Clases no Balanceadas: No aplica, es una variable numérica continua

Problemas de Formato: No en la BD (INT), pero el origen traía artefactos de punto flotante (p. ej. 56.999...) que requieren redondeo

Problemas de Estandarización: Sí, conviene escalar (rangos distintos) para algoritmos sensibles a la escala

Distribución de Datos: aproximadamente simétrica (campana); con un pico pronunciado en 0

Sesgo: Sin sesgo apreciable (simétrica)

Múltiples Distribuciones: No

Feature: currency

Datos Faltantes: Sí, 52 registros (4.95%)

Anomalías: Sí, variable constante (sin variabilidad)

Clases no Balanceadas: No aplica, variable constante (1 clase)

Problemas de Formato: Sí, es una variable categórica (texto): requiere codificación para modelado

Problemas de Estandarización: No

Distribución de Datos: Categórica (distribución de frecuencias por clase)

Sesgo: No aplica (variable categórica)

Múltiples Distribuciones: No

Feature: salary_satisfaction

Datos Faltantes: No

Anomalías: No

Clases no Balanceadas: No, las 5 clases están balanceadas (ratio min/max=0.879)

Problemas de Formato: No, es una variable numérica

Problemas de Estandarización: No

Distribución de Datos: aproximadamente uniforme

Sesgo: Sin sesgo apreciable (simétrica)

Múltiples Distribuciones: No

Observaciones del dataset

- Presentan datos faltantes las variables: gender, age, income_flux, outgoing_flux, education_level, employment_type, currency.
- Los faltantes de currency, income_flux y outgoing_flux están correlacionados (faltante estructurado): cuando falta la moneda, también faltan ingresos y egresos.
- income_flux y outgoing_flux tienen magnitudes muy superiores al resto de variables, por lo que requieren normalización/estandarización.
- education_level está desbalanceada: domina 'Bachelor'.
- Variables constantes (sin variabilidad): country, currency.
- married es booleana almacenada como 0/1 y age son enteros almacenados como decimal: ambos presentan problemas de formato menores.
- income_flux y outgoing_flux presentan distribuciones sesgadas a la derecha; un pico en 0 corresponde a personas desempleadas.

Conjunto de datos: pia_data_03 (tabla salaries)

Dimensiones: 2333 registros x 15 columnas.

Informe de hallazgos por característica generado a partir del análisis exploratorio de datos (EDA).

Análisis por característica

Feature: gender

Datos Faltantes: Sí, 116 registros (4.97%)

Anomalías: No

Clases no Balanceadas: No, las 2 clases están balanceadas (ratio min/max=0.985)

Problemas de Formato: Sí, es una variable categórica (texto): requiere codificación para modelado

Problemas de Estandarización: No

Distribución de Datos: Categórica (distribución de frecuencias por clase)

Sesgo: No aplica (variable categórica)

Múltiples Distribuciones: No

Feature: age

Datos Faltantes: Sí, 46 registros (1.97%)

Anomalías: No

Clases no Balanceadas: No aplica, es una variable numérica continua

Problemas de Formato: Sí, son edades enteras almacenadas como decimal (p. ej. 30.0)

Problemas de Estandarización: Sí, conviene escalar (rangos distintos) para algoritmos sensibles a la escala

Distribución de Datos: aproximadamente uniforme

Sesgo: Sin sesgo apreciable (simétrica)

Múltiples Distribuciones: No

Feature: country

Datos Faltantes: No

Anomalías: No

Clases no Balanceadas: No, las 8 clases están balanceadas (ratio min/max=0.787)

Problemas de Formato: Sí, es una variable categórica (texto): requiere codificación para modelado

Problemas de Estandarización: No

Distribución de Datos: Categórica (distribución de frecuencias por clase)

Sesgo: No aplica (variable categórica)

Múltiples Distribuciones: No

Feature: married

Datos Faltantes: No

Anomalías: No

Clases no Balanceadas: No, las 2 clases están balanceadas (ratio min/max=0.93)

Problemas de Formato: Sí, es booleana representada como entero 0/1 (requiere mapeo a True/False)

Problemas de Estandarización: No

Distribución de Datos: Categórica (distribución de frecuencias por clase)

Sesgo: No aplica (variable categórica)

Múltiples Distribuciones: No

Feature: family_members

Datos Faltantes: No

Anomalías: No

Clases no Balanceadas: No aplica, es una variable numérica discreta

Problemas de Formato: No, es una variable numérica

Problemas de Estandarización: No

Distribución de Datos: aproximadamente uniforme

Sesgo: Sin sesgo apreciable (simétrica)

Múltiples Distribuciones: No

Feature: industry

Datos Faltantes: No

Anomalías: No

Clases no Balanceadas: No, las 10 clases están balanceadas (ratio min/max=0.82)

Problemas de Formato: Sí, es una variable categórica (texto): requiere codificación para modelado

Problemas de Estandarización: No

Distribución de Datos: Categórica (distribución de frecuencias por clase)

Sesgo: No aplica (variable categórica)

Múltiples Distribuciones: No

Feature: income_flux

Datos Faltantes: Sí, 87 registros (3.73%)

Anomalías: Sí, artefacto de techo: 765 valores == 200,000

Clases no Balanceadas: No aplica, es una variable numérica continua

Problemas de Formato: No, es una variable numérica

Problemas de Estandarización: Sí, los montos están en múltiples monedas ['AUD', 'BRL', 'CAD', 'CNY', 'EUR', 'GBP', 'INR', 'JPY'] sin conversión a una moneda común; además requiere escalamiento

Distribución de Datos: aproximadamente simétrica (campana); con un pico pronunciado en 0

Sesgo: Sin sesgo apreciable (simétrica)

Múltiples Distribuciones: Sí, una subdistribución por cada moneda/país

Feature: outgoing_flux

Datos Faltantes: Sí, 116 registros (4.97%)

Anomalías: No

Clases no Balanceadas: No aplica, es una variable numérica continua

Problemas de Formato: No, es una variable numérica

Problemas de Estandarización: Sí, los montos están en múltiples monedas ['AUD', 'BRL', 'CAD', 'CNY', 'EUR', 'GBP', 'INR', 'JPY'] sin conversión a una moneda común; además requiere escalamiento

Distribución de Datos: sesgada (cola hacia valores altos)

Sesgo: A la derecha (positivo)

Múltiples Distribuciones: Sí, una subdistribución por cada moneda/país

Feature: education_level

Datos Faltantes: Sí, 69 registros (2.96%)

Anomalías: No

Clases no Balanceadas: Sí, existen 5 clases y están desbalanceadas (ratio min/max=0.094); domina 'Bachelor'

Problemas de Formato: Sí, es una variable categórica (texto): requiere codificación para modelado

Problemas de Estandarización: No

Distribución de Datos: Categórica (distribución de frecuencias por clase)

Sesgo: No aplica (variable categórica)

Múltiples Distribuciones: No

Feature: years_of_experience

Datos Faltantes: No

Anomalías: No

Clases no Balanceadas: No aplica, es una variable numérica discreta

Problemas de Formato: No, es una variable numérica

Problemas de Estandarización: Sí, conviene escalar (rangos distintos) para algoritmos sensibles a la escala

Distribución de Datos: aproximadamente uniforme

Sesgo: Sin sesgo apreciable (simétrica)

Múltiples Distribuciones: No

Feature: employment_type

Datos Faltantes: Sí, 69 registros (2.96%)

Anomalías: No

Clases no Balanceadas: No, las 4 clases están balanceadas (ratio min/max=0.93)

Problemas de Formato: Sí, es una variable categórica (texto): requiere codificación para modelado

Problemas de Estandarización: No

Distribución de Datos: Categórica (distribución de frecuencias por clase)

Sesgo: No aplica (variable categórica)

Múltiples Distribuciones: No

Feature: remote_work_percentage

Datos Faltantes: No

Anomalías: No

Clases no Balanceadas: No aplica, es una variable numérica continua

Problemas de Formato: No en la BD (INT), pero el origen traía artefactos de punto flotante (p. ej. 56.999...) que requieren redondeo

Problemas de Estandarización: Sí, conviene escalar (rangos distintos) para algoritmos sensibles a la escala

Distribución de Datos: aproximadamente simétrica (campana); con un pico pronunciado en 0

Sesgo: Sin sesgo apreciable (simétrica)

Múltiples Distribuciones: No

Feature: currency

Datos Faltantes: Sí, 116 registros (4.97%)

Anomalías: No

Clases no Balanceadas: No, las 8 clases están balanceadas (ratio min/max=0.778)

Problemas de Formato: Sí, es una variable categórica (texto): requiere codificación para modelado

Problemas de Estandarización: Sí, múltiples monedas conviviendo: impide comparar montos directamente

Distribución de Datos: Categórica (distribución de frecuencias por clase)

Sesgo: No aplica (variable categórica)

Múltiples Distribuciones: No

Feature: salary_satisfaction

Datos Faltantes: No

Anomalías: No

Clases no Balanceadas: No, las 5 clases están balanceadas (ratio min/max=0.916)

Problemas de Formato: No, es una variable numérica

Problemas de Estandarización: No

Distribución de Datos: aproximadamente uniforme

Sesgo: Sin sesgo apreciable (simétrica)

Múltiples Distribuciones: No

Observaciones del dataset

- Presentan datos faltantes las variables: gender, age, income_flux, outgoing_flux, education_level, employment_type, currency.
- Los faltantes de currency, income_flux y outgoing_flux están correlacionados (faltante estructurado): cuando falta la moneda, también faltan ingresos y egresos.
- income_flux y outgoing_flux tienen magnitudes muy superiores al resto de variables, por lo que requieren normalización/estandarización.
- income_flux presenta un artefacto de techo: 765 registros con el valor máximo 200,000 (truncamiento artificial / outliers).
- education_level está desbalanceada: domina 'Bachelor'.
- Conviven múltiples monedas; income_flux/outgoing_flux muestran múltiples distribuciones y no son comparables sin conversión.
- married es booleana almacenada como 0/1 y age son enteros almacenados como decimal: ambos presentan problemas de formato menores.
- income_flux y outgoing_flux presentan distribuciones sesgadas a la derecha; un pico en 0 corresponde a personas desempleadas.