

Asignación 01: Análisis de Problemas en Datasets

Objetivo

El objetivo de esta asignación es detectar problemas comunes en los conjuntos de datos almacenados en las distintas bases de datos alojadas en el entorno virtual.

Objetivos Específicos

- Explorar las distintas bases de datos.
- Analizar los datos encontrados para identificar posibles problemas de calidad de datos.
- Examinar las distribuciones de las variables para descubrir información útil, de interés o curiosa.

Instrucciones

Se debe analizar los tres conjuntos de datos almacenados en las siguientes bases de datos:

- **pia_data_01**
- **pia_data_02**
- **pia_data_03**

El análisis debe centrarse en la detección de los siguientes problemas:

- **Datos faltantes (Missing Data)**
- **Problemas de escala (Scaling Issues)**
- **Clases desbalanceadas (Imbalanced Classes)**

- **Valores anómalos (Outliers)**
- **Problemas de formato**
- **Problemas de estandarización**

Además, se debe analizar la distribución de cada variable para identificar patrones, sesgos o particularidades.

Entregable

Por cada conjunto de datos, se debe generar un informe detallado con los hallazgos obtenidos **para cada una de las características** del dataset. El informe puede seguir el siguiente formato de ejemplo o adaptarse a otro formato estructurado:

Ejemplo de Reporte

Feature: Age

- Datos Faltantes: No/Sí
- Anomalías: No/Sí
- Clases no Balanceadas: No, las clases están balanceadas / Sí, existen 3 clases y el conteo no es igual
- Problemas de Formato: No, es una variable numérica / Sí, es una variable categórica
- Problemas de Estandarización: No / Sí, la representación del número varía
- Distribución de Datos: Tiene una forma bimodal/uniforme/campana de Gauss/etc.
- Sesgo: A la izquierda / A la derecha
- Múltiples Distribuciones: No / Sí

Feature: Gender

- .
- .
- .

Observaciones del dataset:

- Es posible que las variables X, Y, Z requieran estandarización
- Se observó que la variable W presenta una distribución altamente sesgada
- etc.

- .
- .
- .

Conclusiones finales:

- Las variables X, Y, Z requieren estandarización en todas las bases de datos.
- Etc.

Cada estudiante deberá entregar un documento en formato PDF con los análisis realizados para cada base de datos y un resumen de las observaciones generales.

Formato de Entrega: Documento en formato PDF

Medio de Entrega: GES